



# ► TALENTO TECH



**TIC**



Universidad  
Tecnológica  
de Bolívar

[www.utb.edu.co/talento-tech](http://www.utb.edu.co/talento-tech)

[www.utb.edu.co/talento-tech](http://www.utb.edu.co/talento-tech)

# Tarifa AI

---

BOOTCAMP INTELIGENCIA ARTIFICIAL

GRUPO: BAS-1139-202406

**EJECUTOR TÉCNICO:**  
**GUILLERMO BEJARANO REYES**

UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR - UTB

# Aplicación de Inteligencia Artificial para desarrollar un prototipo de sistema inteligente que utilice técnicas de Machine Learning

## Predicción de la Cantidad de Turistas en una Ciudad

### Integrantes

Yeizon Martínez Vergara

Negan Gracia Lopéz

Jesús David Oquendo Aduén

Alexander Torres

Jorge Guerrero

Lineth María Chamorro Choperena

# Tabla de contenido

Contextualización del problema.....	5
Sectores para abordar :Energía Eléctrica en la Región Caribe.....	5
• Descripción de los sectores.....	5
• Importancia de los sectores.....	5
Pregunta de investigación.....	5
Objetivo General.....	5
Objetivos Específicos.....	5
Metodología de Trabajo.....	6
Herramientas a utilizar.....	11
Desarrollo del proyecto.....	11
Conclusiones del modelo.....	13
Observaciones del histórico (2020-2024):.....	13
Observaciones de las predicciones (2025):.....	14
Conclusiones generales:.....	14
Aplicaciones prácticas de estas conclusiones:.....	15
Referencias bibliográficas.....	16

# Contextualización del problema

## Sectores para abordar :Energía Eléctrica en la Región Caribe

- **Descripción de los sectores**

La energía eléctrica es fundamental para el desarrollo económico y social, y en la región Caribe colombiana es especialmente crítica debido a su clima cálido y la alta demanda de consumo. Sin embargo, esta región ha enfrentado constantes problemas en el suministro de energía, afectando tanto a los hogares como a las empresas. La infraestructura deficiente y los altos costos de distribución han llevado a una calidad de servicio inestable, con interrupciones frecuentes y una variación significativa en las tarifas.

- **Importancia de los sectores**

Un suministro de energía confiable y asequible es clave para mejorar la calidad de vida en la región y para el desarrollo económico. Predecir futuros costos de energía puede ayudar a determinar las causas de las variaciones en las tarifas y optimizar la distribución de energía para reducir los costos y mejorar la estabilidad del servicio. Esto beneficiaría a la población en general y permitiría un uso más eficiente de los recursos disponibles.

## Pregunta de investigación

¿Cómo se puede predecir la fluctuación de tarifas en los diferentes estratos socioeconómicos de la Región Caribe para aplicar estrategias de prevención y ahorro?

## Objetivo General

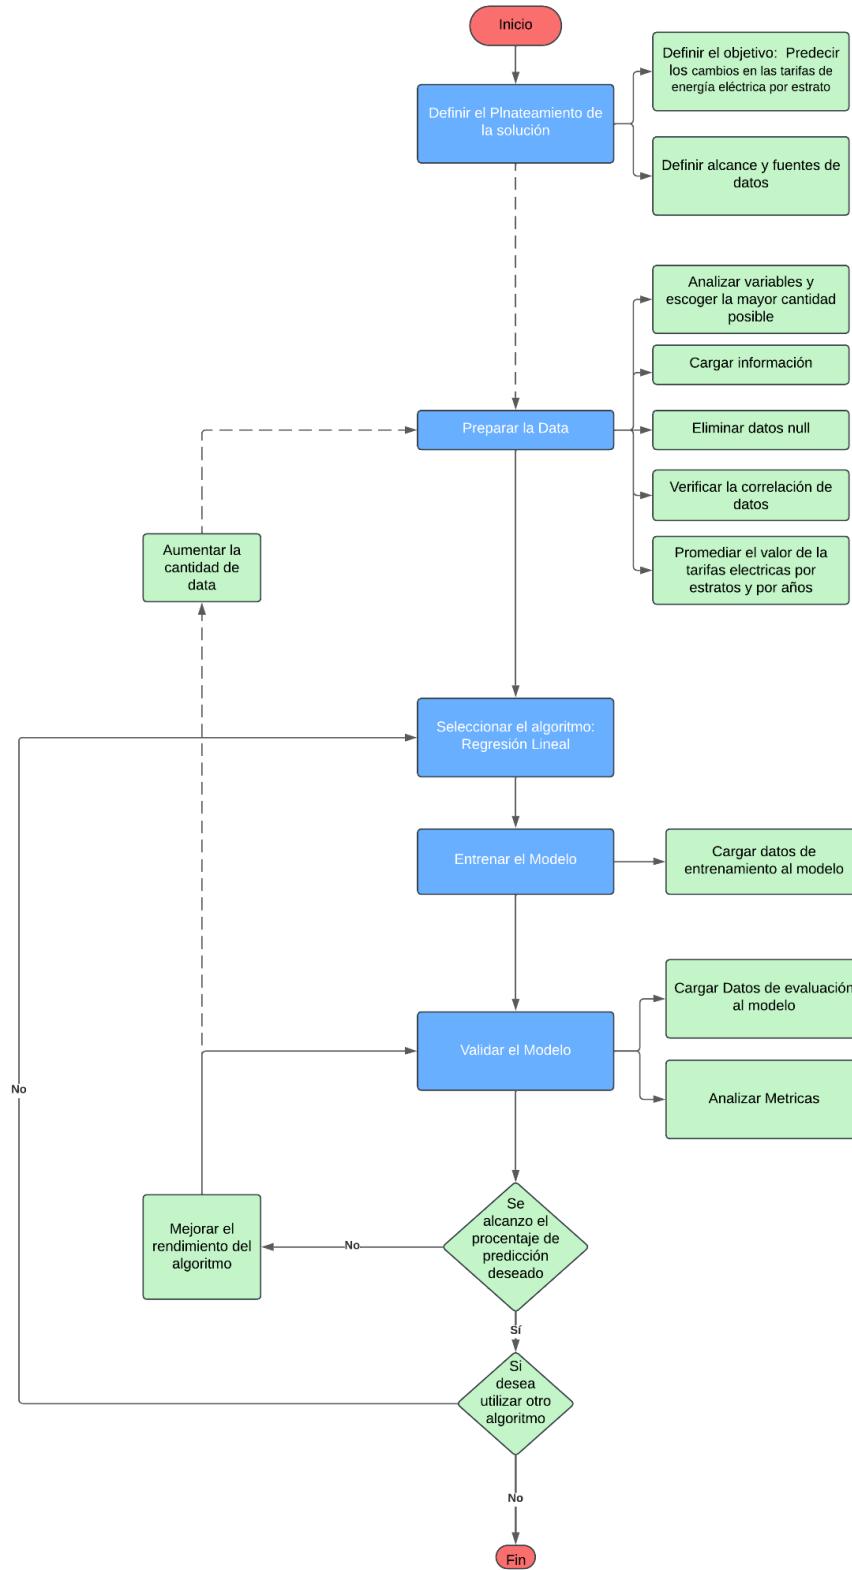
Desarrollar un sistema predictivo que permita anticipar los cambios en las tarifas de energía eléctrica por estrato, para ofrecer al usuario una herramienta que le permita conocer sus tarifas futuras y mejorar la planificación financiera de los recibos e implementar estrategias de ahorro en su consumo de energía.

## Objetivos Específicos

1. Recopilar y analizar datos históricos de tarifas de energía eléctrica para los diferentes estratos en la región Caribe.
2. Seleccionar un modelo adecuado de machine learning para hacer predicciones basadas en la data.
3. Entrenar un modelo de machine learning para predecir tarifas futuras según los estratos.

4. Implementar un sistema que ayude a los usuarios a tomar decisiones financieras a partir de los cambios tarifarios.

# Metodología de Trabajo



1. *Definir el planteamiento de la solución:* El modelo de regresión lineal se entrenará con datos históricos de tarifas de energía eléctrica por estrato en la Región Caribe, identificando patrones y tendencias a lo largo del tiempo. Utilizando variables como mes, año y estrato socioeconómico, el modelo predecirá las tarifas de los meses faltantes de 2024 y todo 2025. Estas proyecciones permitirán anticipar fluctuaciones, optimizar la planificación financiera y desarrollar estrategias para un consumo energético más eficiente en la región.

2. *Preparar la data:*

- a. Recoger datos históricos de las tarifas eléctricas (kWh) en la región caribe colombiana (Atlántico, Bolívar, Cesar, Magdalena, La Guajira y Sucre) desde enero del año 2020 hasta 31 de octubre del 2024 (La información fue obtenida de la página [Tarifas de Energía Eléctrica – Integrame](#)).
- b. Limpiar y procesar la data (manejar valores nulos, transformación de datos para formato legible del modelo).
- c. El dataset suministrado enlace: [Dataset Tarifas Eléctricas](#)

3. *Seleccionar el Modelo:* Se seleccionó el modelo de regresión lineal debido a su capacidad para capturar relaciones lineales entre las variables independientes, como el mes, el año y el estrato socioeconómico, con las tarifas de energía. Este modelo es adecuado porque permite predecir tendencias futuras de manera clara y sencilla basándose en datos históricos. A continuación, se presenta el código utilizado para la implementación y predicción de las tarifas para los últimos meses de 2024 y todo 2025:

```
from sklearn.linear_model import LinearRegression

# Variables independientes (Año y MES)

X = data[['Año', 'MES']]

# Crear un diccionario para almacenar los modelos y predicciones

modelos = {}

for estrato in ['Estrato 1', 'Estrato 2', 'Estrato 3', 'Estrato 4', 'Estrato 5', 'Estrato 6']:

    # Variable dependiente (tarifa de cada estrato)

    y = data[estrato]

    # Crear y entrenar el modelo

    modelo = LinearRegression()

    modelo.fit(X, y)

    modelos[estrato] = modelo

    # Mostrar los coeficientes del modelo

    print(f"Modelo para {estrato}:")

    print(f"Coeficientes: {modelo.coef_}, Intercepto: {modelo.intercept_}\n")
```

Este código define el modelo de regresión lineal y genera los conjuntos de datos necesarios para predecir las tarifas de energía en los meses faltantes del 2024 y todos los meses del 2025.

4. *Entrenar el modelo:* El entrenamiento del modelo implica utilizar los datos históricos para que el modelo de regresión lineal aprenda la relación entre las características predictivas (variables independientes) y el valor objetivo (variable dependiente). En este caso:
  - a. Datos históricos: Se utilizan los datos de tarifas por estrato, junto con las variables Año y MES.
  - b. Entrenamiento: Para cada estrato, se filtran los datos correspondientes (estrato\_data), se separan las características predictivas ( $X = \text{Año, MES}$ ) y el objetivo ( $y = \text{Tarifa}$ ), y se ajusta el modelo con la función `model.fit(X, y)`.

Esto permite que el modelo entienda las tendencias en las tarifas de energía eléctrica para cada estrato basado en el tiempo.

5. *Probar el modelo:* Probar el modelo consiste en evaluar su desempeño para determinar qué tan bien puede predecir las tarifas de energía en datos que son desconocidos.
  - Entrenar el modelo con el conjunto de entrenamiento.
  - Predecir las tarifas de energía en el conjunto de prueba.
  - Comparar las predicciones con los valores reales utilizando métricas de evaluación como el Error Cuadrático Medio (MSE) o el Coeficiente de Determinación ( $R^2$ ).

Esto es esencial para garantizar que el modelo pueda predecir valores cercanos a la realidad y tenga un buen desempeño en datos futuros.

6. *Ajustar el modelo:* Después de estas predicciones para el año 2025, se busca hacer un ajuste del modelo donde se puedan incluir más variables que ayuden a mejorar su precisión a futuro.
7. *Hacer predicciones :* Utilizar el modelo entrenado para predecir el valor promedio de las tarifa según el estrato para cada uno de los mes del 2025.

## Análisis de Datos

Visualización de los datos históricos:

Ejemplo: previsualización de los primeros 20 datos históricos del promedio de la tarifa de energía (kWh) desde el mes 1 del 2020 hasta el mes 10 del 2024 en la región caribe.



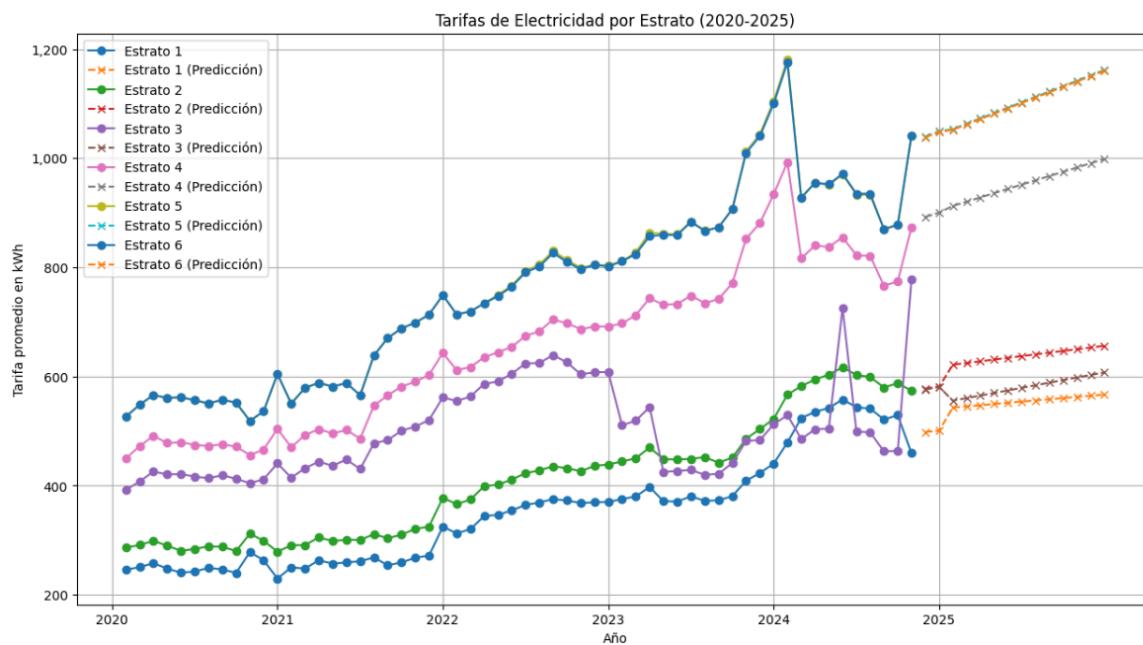
	Año	MES	Estrato 1	Estrato 2	Estrato 3	Estrato 4	Estrato 5	Estrato 6
0	2020	ENERO	245.980597	286.330071	392.302471	449.859697	526.675082	526.296112
1	2020	FEBRERO	250.610156	291.208048	407.437639	472.119295	548.121996	548.121996
2	2020	MARZO	257.933017	298.872883	425.735890	491.212269	565.990762	565.990762
3	2020	ABRIL	248.017644	289.919334	420.669283	478.106086	560.773331	560.773331
4	2020	MAYO	240.517154	280.543016	421.128402	479.537998	562.024366	562.024366

Visualización de los datos que arroja el modelo desde el mes 11 del 2024 hasta el mes 12 del 2025.

Año	MES	Estrato 1	Estrato 2	Estrato 3	Estrato 4	Estrato 5	Estrato 6
2024	11	498.393.037	578.030.968	576.149.161	892.376.584	1.039.428.749	1.038.092.424
2024	12	500.557.945	581.191.306	580.857.177	900.191.305	1.049.270.935	1.047.908.926
2025	1	543.132.855	621.508.892	555.726.304	912.548.438	1.053.358.210	1.052.064.640
2025	2	545.297.763	624.669.229	560.434.321	920.363.159	1.063.200.397	1.061.881.141
2025	3	547.462.671	627.829.567	565.142.337	928.177.881	1.073.042.584	1.071.697.642
2025	4	549.627.579	630.989.905	569.850.353	935.992.602	1.082.884.771	1.081.514.143
2025	5	551.792.486	634.150.243	574.558.370	943.807.323	1.092.726.957	1.091.330.644
2025	6	553.957.394	637.310.581	579.266.386	951.622.044	1.102.569.144	1.101.147.146
2025	7	556.122.302	640.470.919	583.974.402	959.436.765	1.112.411.331	1.110.963.647
2025	8	558.287.210	643.631.257	588.682.418	967.251.486	1.122.253.518	1.120.780.148
2025	9	560.452.118	646.791.595	593.390.435	975.066.207	1.132.095.705	1.130.596.649
2025	10	562.617.026	649.951.933	598.098.451	982.880.928	1.141.937.892	1.140.413.150
2025	11	564.781.933	653.112.270	602.806.467	990.695.649	1.151.780.079	1.150.229.651
2025	12	566.946.841	656.272.608	607.514.484	998.510.370	1.161.622.265	1.160.046.152

## Gráfico

La siguiente imagen, muestra la gráfica de los datos históricos y de la predicción del modelo:



## Herramientas a utilizar

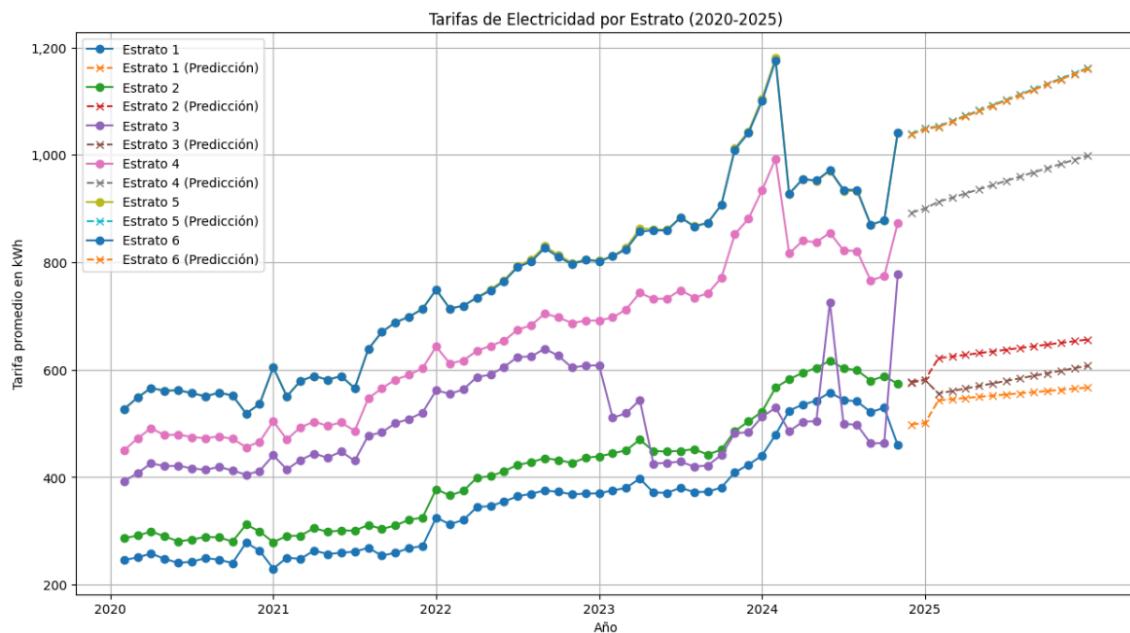
### Justificación para su uso

- Python
- Collab
- Documentación en la nube de Google
- Microsoft Teams

## Desarrollo del proyecto

1. Implementación del código en Google Colab.
2. Descripción de los pasos seguidos de la metodología
3. Presentación de los resultados obtenidos.

## Conclusiones del modelo



### Observaciones históricas (2020-2024)

El desarrollo de una inteligencia artificial (IA) predictiva en el sector energético se fundamenta en el análisis de datos históricos y patrones de consumo, con el objetivo de generar proyecciones confiables que permitan a los usuarios anticiparse a fluctuaciones en las tarifas. A continuación, se presenta un análisis detallado de las tendencias históricas y las proyecciones para 2025, que sirvieron como base para el diseño del modelo predictivo.

#### Incrementos progresivos por estrato

Desde 2020 hasta 2024, se observó un aumento sostenido en las tarifas eléctricas promedio. Este incremento, aunque generalizado, presentó variaciones por estrato socioeconómico:

- **Estratos bajos (1 y 2):** Los incrementos fueron más moderados, posiblemente debido a la influencia de subsidios gubernamentales, que estabilizaron las tarifas en un rango de 300 a 400 pesos por kWh en 2024.
- **Estratos altos (4, 5 y 6):** Los aumentos fueron más pronunciados, alcanzando un promedio superior a los 1,200 pesos por kWh en el estrato

6. Esto refleja la ausencia de subsidios y una mayor exposición a factores de mercado.

### Brecha entre estratos

El análisis muestra una clara segmentación de costos entre los estratos bajos y altos. Esta brecha subraya la necesidad de estrategias diferenciadas para gestionar los costos energéticos en cada grupo socioeconómico.

### Proyecciones para 2025

El modelo de IA desarrollado se apoya en patrones históricos para generar predicciones más precisas y consistentes. Las principales proyecciones incluyen:

#### Tendencia ascendente moderada

Se anticipa un aumento continuo en las tarifas promedio, aunque con una menor variabilidad que en años anteriores. Esto se debe a la inclusión de técnicas de suavización en el modelo predictivo.

#### Incrementos diferenciados por estrato

- **Estratos bajos (1 y 2):** Las tarifas permanecerán relativamente estables, dependiendo de la continuidad de los subsidios.
- **Estratos altos (5 y 6):** Se proyecta un incremento más significativo, reflejando una mayor carga económica para estos hogares.

#### Reducción de la variabilidad

Las proyecciones muestran patrones más consistentes y menos fluctuaciones extremas, lo que permitirá a los usuarios y planificadores anticipar cambios con mayor precisión.

### Aplicaciones del Modelo Predictivo

La IA predictiva desarrollada tiene aplicaciones prácticas orientadas a mejorar la toma de decisiones tanto a nivel de usuario como de política pública. Entre sus funcionalidades destacan:

#### 1. Estimación personalizada de tarifas

El sistema permite a los usuarios obtener predicciones del costo por kilovatio-hora (kWh) en función de:

- **Mes y región seleccionada:** Basado en datos históricos ajustados a cada contexto.

- **Consumo mensual estimado:** La aplicación calcula el costo total proyectado, brindando una visión clara de los posibles gastos energéticos.

## 2. Visualización de tendencias

El modelo incluye herramientas gráficas que permiten:

- Identificar variaciones históricas y proyectadas.
- Comparar tarifas entre estratos y regiones.
- Evaluar cómo las fluctuaciones impactan de manera diferenciada según el nivel socioeconómico.

## 3. Análisis de impacto por estrato

El modelo facilita la identificación de los efectos económicos en distintos grupos, permitiendo a los usuarios evaluar alternativas como energías renovables o medidas de eficiencia energética.

## Conclusiones y Recomendaciones

### Impacto en usuarios y planificación energética

- **Estratos bajos:** Los subsidios actuales estabilizan las tarifas, pero su reducción podría generar incrementos significativos. La planificación del consumo en meses de alta demanda será clave para estos hogares.
- **Estratos altos:** Los aumentos proyectados subrayan la necesidad de explorar opciones como paneles solares o tecnologías de optimización energética.

### Aplicación para la política pública

- Mantener subsidios en estratos bajos es crucial para garantizar la accesibilidad energética.
- Implementar incentivos que promuevan el ahorro energético en los estratos altos contribuirá a reducir la presión económica y a fomentar la sostenibilidad.

### Para mejorar el modelo a futuro se debe:

- Trabajar con datos categorizados por departamentos y analizar el comportamiento histórico de los precios de las tarifas en cada departamento de la costa caribe colombiana.
- Incluir la variable de Nivel de tensión (NT1, NT2, NT3, NT4).
- Entrenar el modelo con estas nuevas variables le brindan al modelo un porcentaje mayor de precisión.



- Al iniciar el año 2026 re-entrenar el modelo con los datos reales del 2025 para ajustar la precisión del modelo.

Aplicación práctica del modelo para los usuarios de la costa caribe colombiana:

**Obtenga una predicción precisa:**

- El sistema devolverá el costo estimado del kilovatio-hora (kWh) para el mes y estratos seleccionados, basado en datos históricos y el modelo de predicción.
- Si el usuario ingresa su consumo mensual estimado (en kWh), la aplicación calculará el costo total proyectado para el mes seleccionado.

**Visualice el impacto del costo:**

- Comparaciones con meses anteriores para observar si los precios han subido o bajado.
- Información sobre cómo el precio podría variar en el tiempo según el estrato.

## Referencias bibliográficas

- Integrame. (n.d.). *Tarifas de energía eléctrica*. Integrame. Recuperado el 22 de noviembre de 2024, de <https://www.integrame.gov.co/tablero/tarifas-de-energia-electrica/>



Universidad  
Tecnológica  
de Bolívar

[www.utb.edu.co/talento-tech](http://www.utb.edu.co/talento-tech)