

Predicción de Batería de VE:



BatBattery: El Futuro de las Baterías



Universidad
Tecnológica
de Bolívar

INTELIGENCIA ARTIFICIAL
Nivel Explorador

INTELIGENCIA ARTIFICIAL - BAS-1038-202406


www.utb.edu.co/talento-tech

Integrantes:

Rafael Bustamante Lara
Leonidas Llorente López
Alfredo Lozada Fuentes
Owen Tovar Puello
Kaleth Maza Barrio



Contextualización del Problema




Los vehículos eléctricos están transformando la movilidad y la lucha contra el cambio climático.

Sin embargo, la gestión de sus baterías usadas plantea un desafío ambiental urgente.

La falta de infraestructura de reciclaje expone al mundo a riesgos de contaminación y pérdida de recursos.

La Inteligencia Artificial emerge como la clave para prever este problema y anticipar soluciones eficientes.

Con IA, podemos guiar hacia un futuro sostenible y una economía circular que maximice el reciclaje y reutilización.




Sectores para abordar :

- ❑ Transporte
- ❑ Ambiente
- ❑ Tecnologías de la Información



Pregunta de investigación


¿Cómo puede la Inteligencia Artificial (IA) predecir la cantidad de baterías de vehículos eléctricos (VE) que se desecharán anualmente, considerando factores como el ciclo de vida de las baterías y patrones de uso?



Objetivo General

Desarrollar un modelo predictivo basado en técnicas de Machine Learning (ML) para estimar la cantidad de baterías de vehículos eléctricos al final de su vida útil anualmente


Objetivos Específicos



Desarrollar un modelo predictivo basado en técnicas de Machine Learning (ML) para estimar la cantidad de baterías de vehículos eléctricos al final de su vida útil anualmente



Entrenar un modelo de Machine Learning capaz de predecir el número de baterías de vehículos eléctricos utilizando los datos recopilados



Evaluar y validar el modelo predictivo, midiendo el Error Absoluto Promedio (Mean Absolute Error - MAE) y su precisión




Proponer recomendaciones basadas en las predicciones generadas, con el fin de optimizar la planificación y el diseño de infraestructuras de reciclaje de baterías

Metodología




Fase 1: Recolección y análisis de datos



Fase 2: Desarrollo del modelo de Machine Learning



Fase 3: Validación y evaluación del modelo



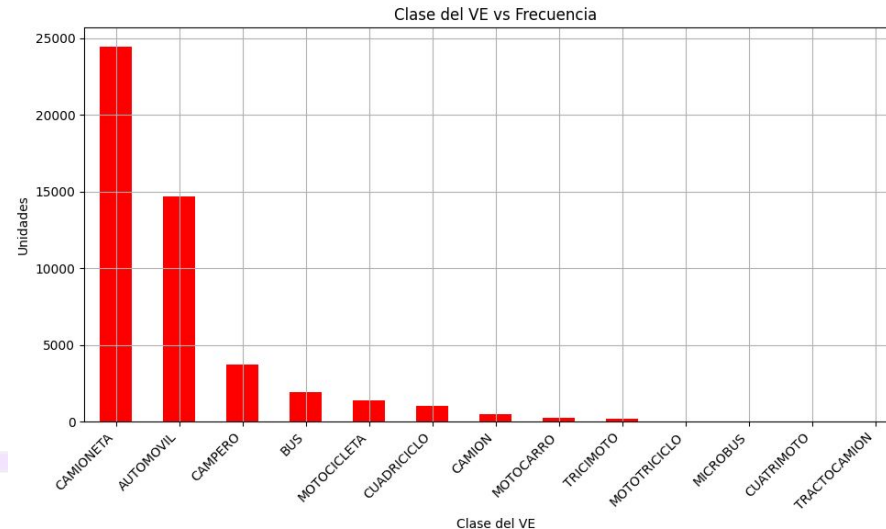

Fase 4: Implementación y análisis de resultados

Desarrollo del Proyecto

Recolección y Limpieza de Datos

✓ Lectura de los datos

```
[ ] 1 # Carga del conjunto de datos de trabajo: 'Numero_de_Vehiculos_Electricos_Hibridos_2024_04_20.csv'
    2
    3 df1 = pd.read_csv(filename1)
```

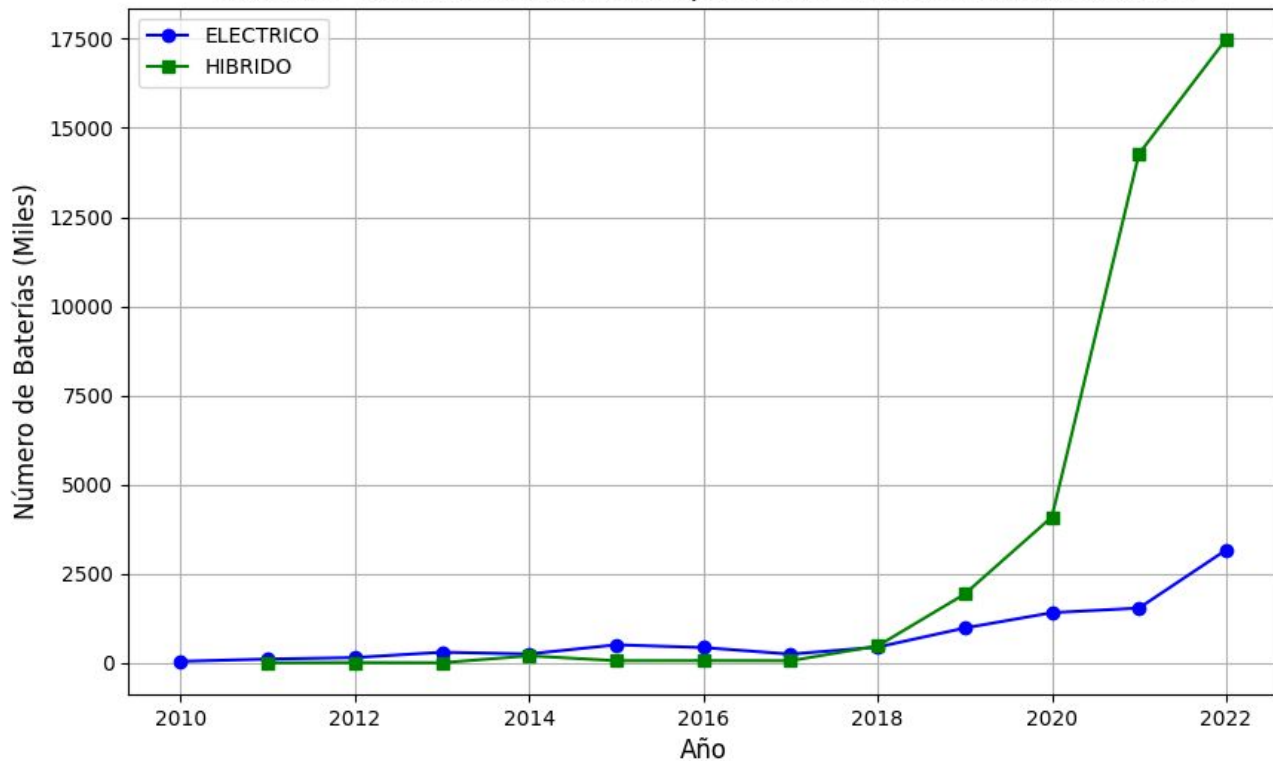


DEPARTAMENTO	
Bogota D.C.	21861
Antioquia	12261
Cundinamarca	3994
Valle del Cauca	2733
Norte de Santander	1903
Risaralda	790
Atlantico	704
Caldas	637
Santander	602
Meta	416
Boyaca	371
Tolima	348
Quindio	251
Huila	215

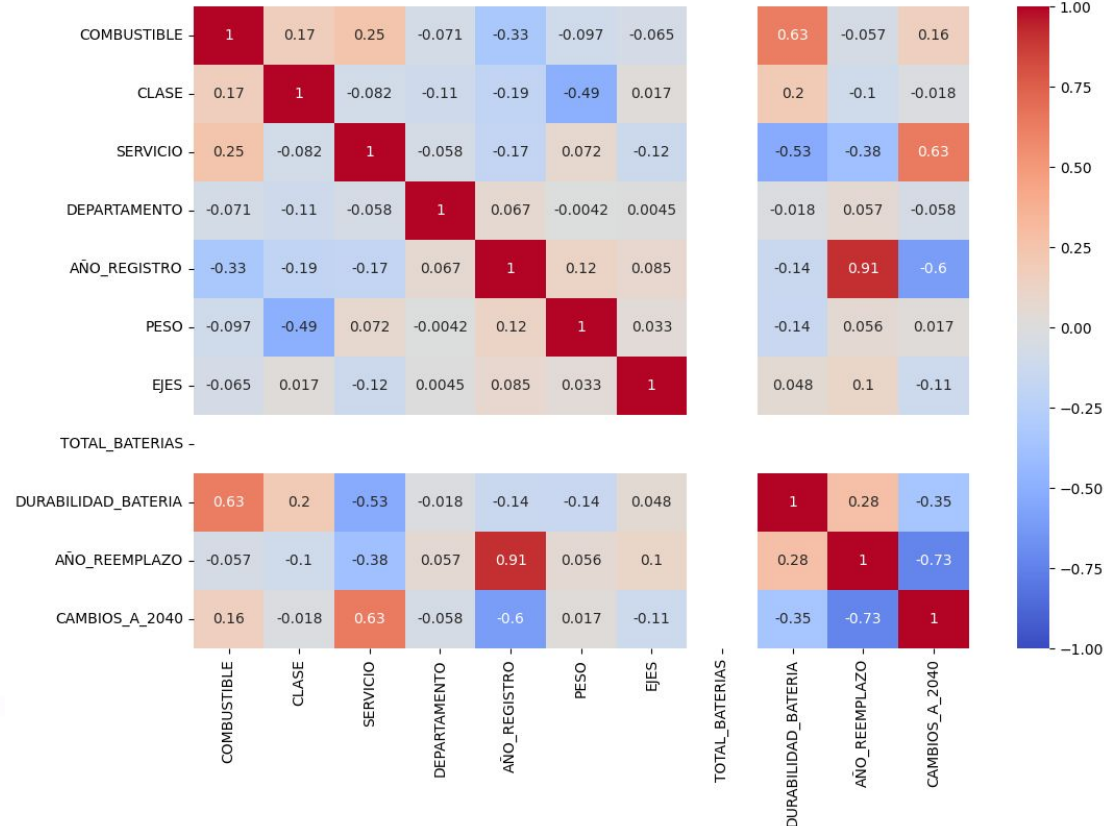
Desarrollo del Proyecto

Desarrollo del modelo de Machine Learning

Total de Baterías Generadas por Año: Eléctricos vs Híbridos



Matriz de Correlación



Desarrollo del Proyecto

Validación y evaluación del modelo

Linear Regression ---> R^2 : 0.6884 ---> MAE: 0.1376

Random Forest ---> R^2 : 0.9821 ---> MAE: 0.0045

XGBoost ---> R^2 : 0.9822 ---> MAE: 0.0044

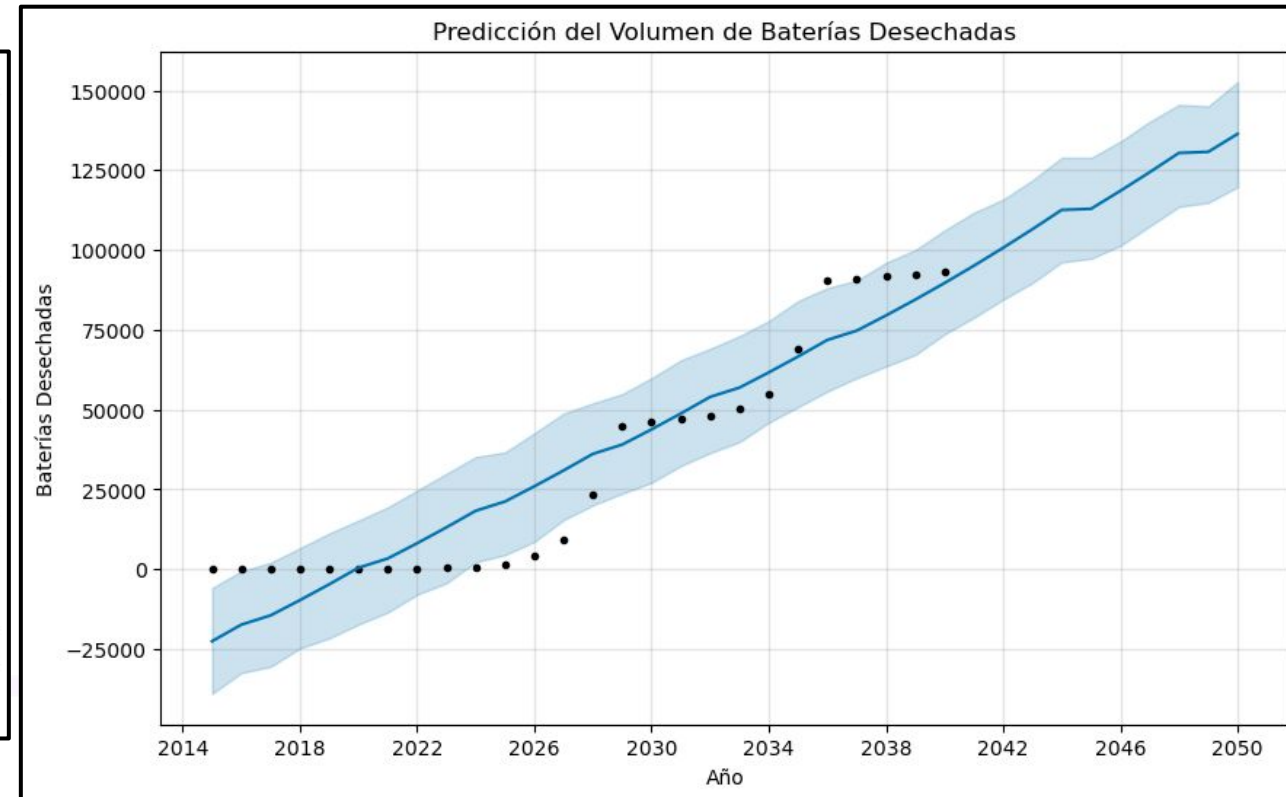
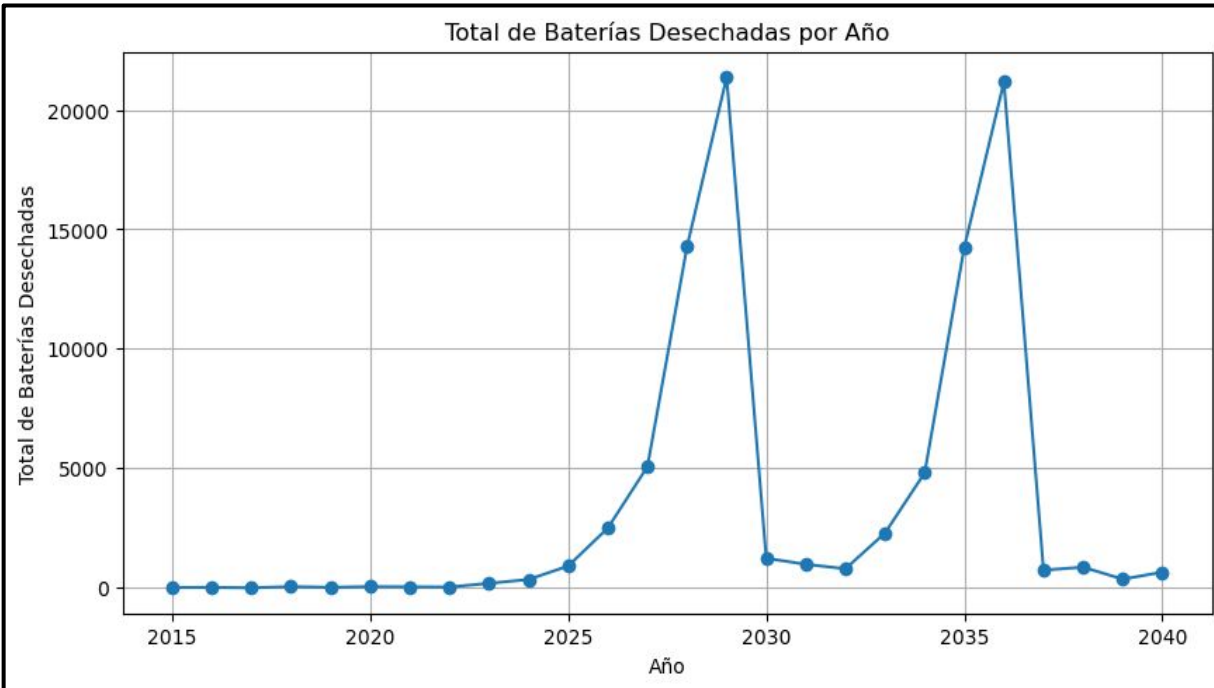
El Modelo con Mejor Rendimiento es: XGBoost con un R^2 de 0.9822.

✓ Paso 3: Entrenamiento de Tres (3) Modelos para Predecir:

```
[ ] 1  # Regresión Lineal:
    2  lr = LinearRegression()
    3  lr.fit(X_train, y_train)
    4
    5  # Random Forest Regressor:
    6  rf = RandomForestRegressor(n_estimators=100, random_state=42)
    7  rf.fit(X_train, y_train)
    8
    9  # XGBoost:
   10  xgbr = xgb.XGBRegressor(objective='reg:squarederror', n_estimators=100, seed=42)
   11  xgbr.fit(X_train, y_train)
   12
```


Desarrollo del Proyecto

Implementación y análisis de resultados



Desarrollo del Proyecto

Implementación y análisis de resultados

BatPredict: El Futuro de la Energía

Descubre cuántas baterías de vehículos eléctricos terminarán su ciclo de vida en los próximos años.

¡El futuro de la energía está en tus manos!

Explora las opciones disponibles en el menú lateral:

- **Número de cambios de baterías por vehículo:** Predecir cuántas baterías serán cambiadas hasta el año deseado según los datos del vehículo.
- **Predecir el número de baterías fuera de servicio:** Estimar el número de baterías fuera de servicio hasta el año deseado y visualizar los resultados en un gráfico.

Predicción de baterías fuera de servicio

Selecciona el año y tipo de gráfico que deseas visualizar.

Año Deseado

2015


2040

2040

¿Qué quieres graficar?

- Total de Baterías Desechadas
- Acumulado

Gráfica Total de Baterías Desechadas por Año



Total de Vehículos por Año



Teniendo como referencia 100 kg promedio por batería, para el año 2040 se espera un total de 655 baterías desechadas, lo que se traduce en aproximadamente 66 toneladas (ton), es decir, 65,500 kilogramos (kg).

Número de cambios de baterías por vehículo hasta el año deseado

Ingresa los valores solicitados para predecir el número de cambios de batería que se esperan hasta el año deseado.

Tipo de Combustible

Híbrido

Año Inicial de Uso

2010

Servicio del Vehículo


Particular

Año Deseado

2030

Se espera un total de 2.00 cambios de batería hasta el 2030.

Conclusiones




Regresión Lineal

Linear Regression ---> R^2 : 0.6884 ---> MAE: 0.1376

Random Forest ---> R^2 : 0.9821 ---> MAE: 0.0045

XGBoost ---> R^2 : 0.9822 ---> MAE: 0.0044



Random Forest

El Modelo con Mejor Rendimiento es: XGBoost con un R^2 de 0.9822.

XGBoost

XGBoost

XGBoost



¡Muchas Gracias!



Universidad
Tecnológica
de Bolívar

Owen de Jesus Tovar Puello (owentovar07@gmail.com)

Alfredo Jose Lozada Fuentes (alfredo.lozada@udea.edu.co)

Rafael Enrique Bustamante Lara (raenbula@yahoo.com)

Leonidas Enrique Llorente Lopez (leonidasllorente@gmail.com)

Kaleth Maza Barrios (kalethmb@gmail.com)